Отчет команды 1 БСМО-11-22:
Александрова Мария Константиновна
Кучеренко Кирилл Иванович
Кузьмин Артём Владимирович
Ляхов Тимофей Алексеевич
Клейменов Андрей Артемович

Задание 1: https://github.com/daixru/knn-phone-brand

Форма опросника:

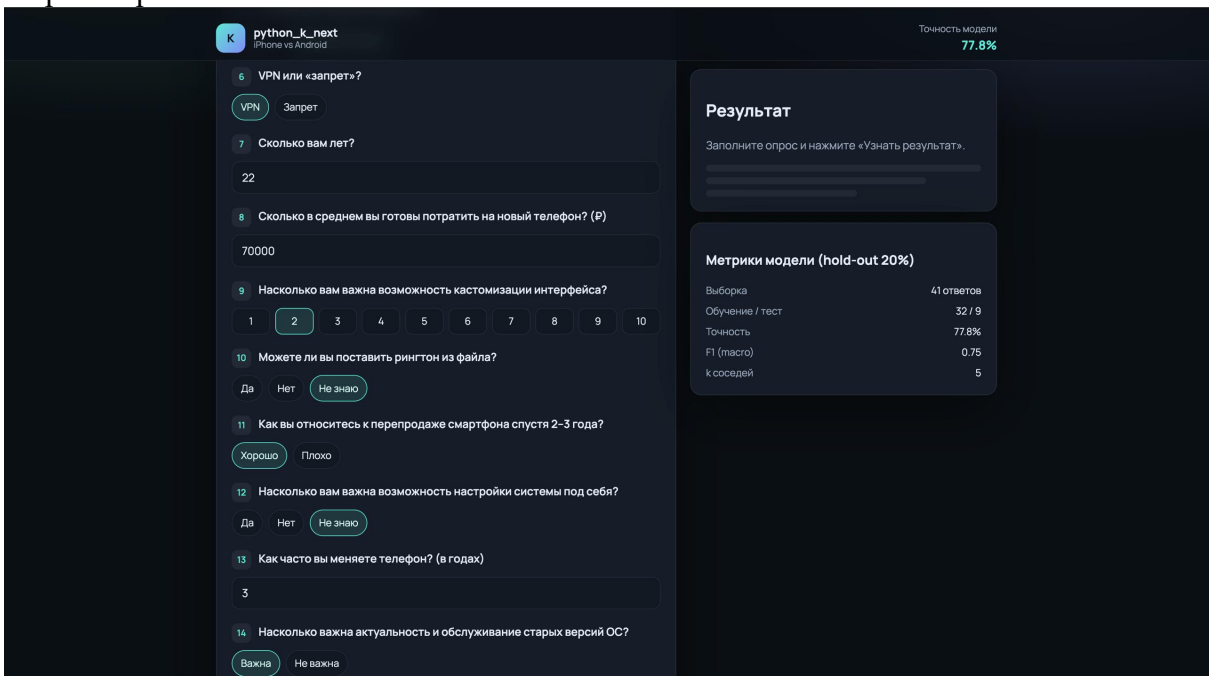


Рисунок 1 – Форма опросника

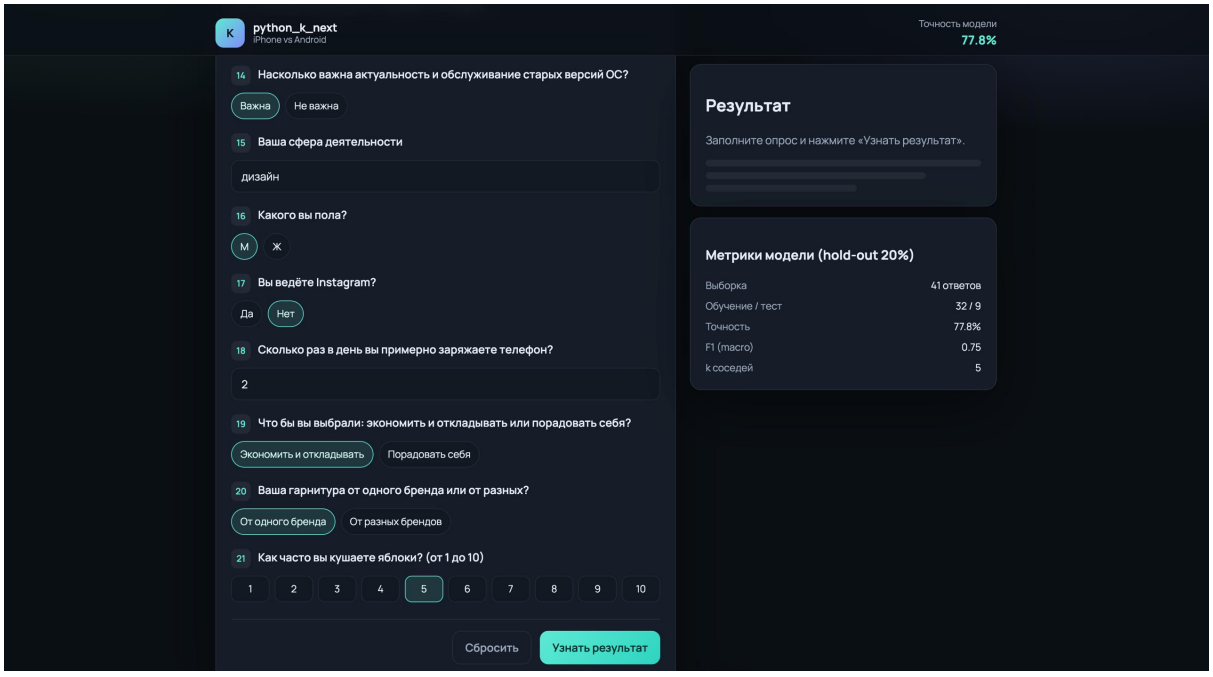


Рисунок 2 – Форма опросника

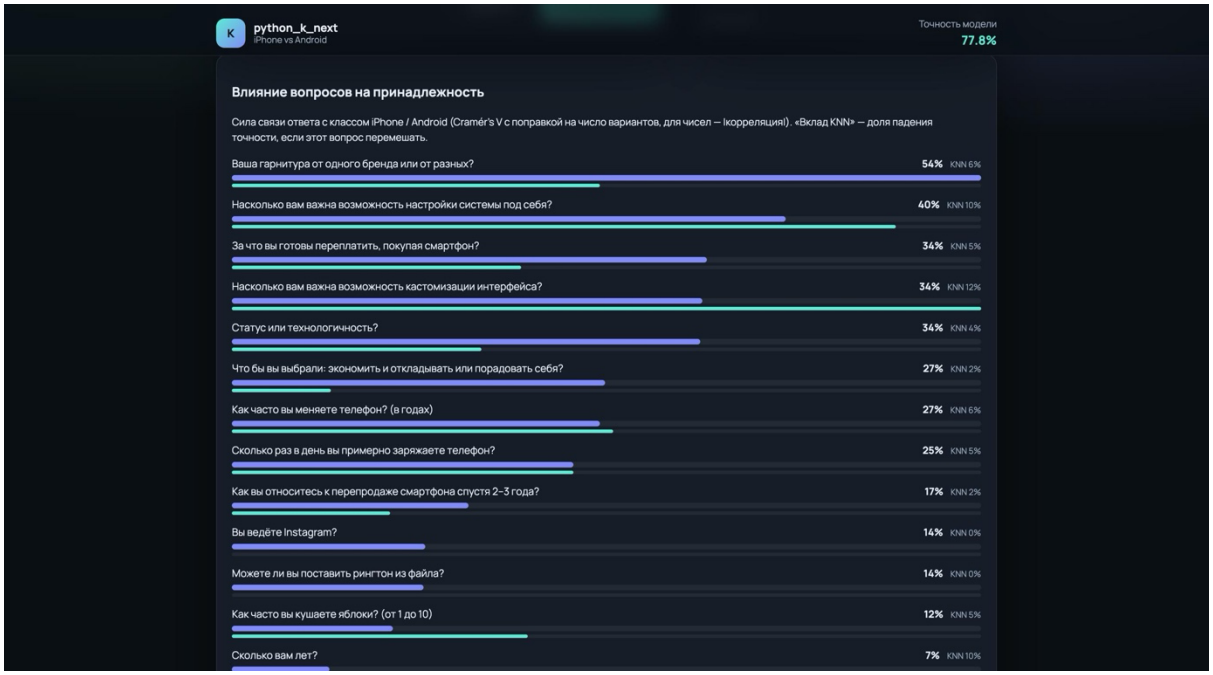


Рисунок 3 – Форма опросника

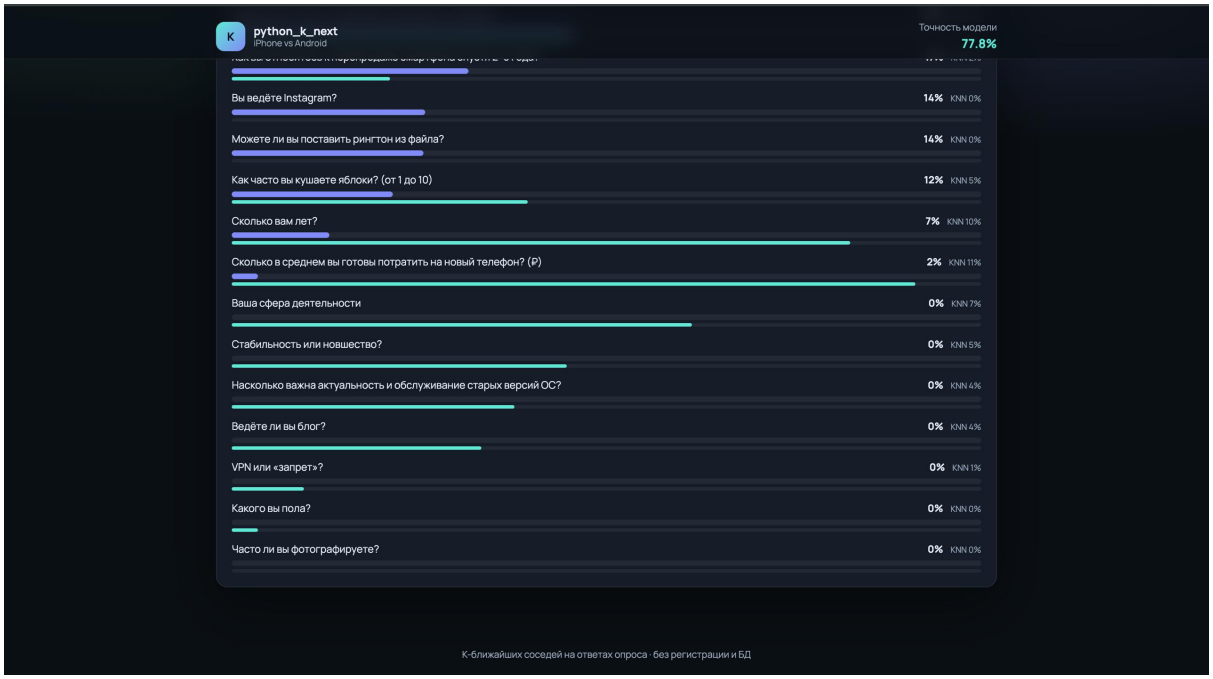


Рисунок 4 – Форма опросника

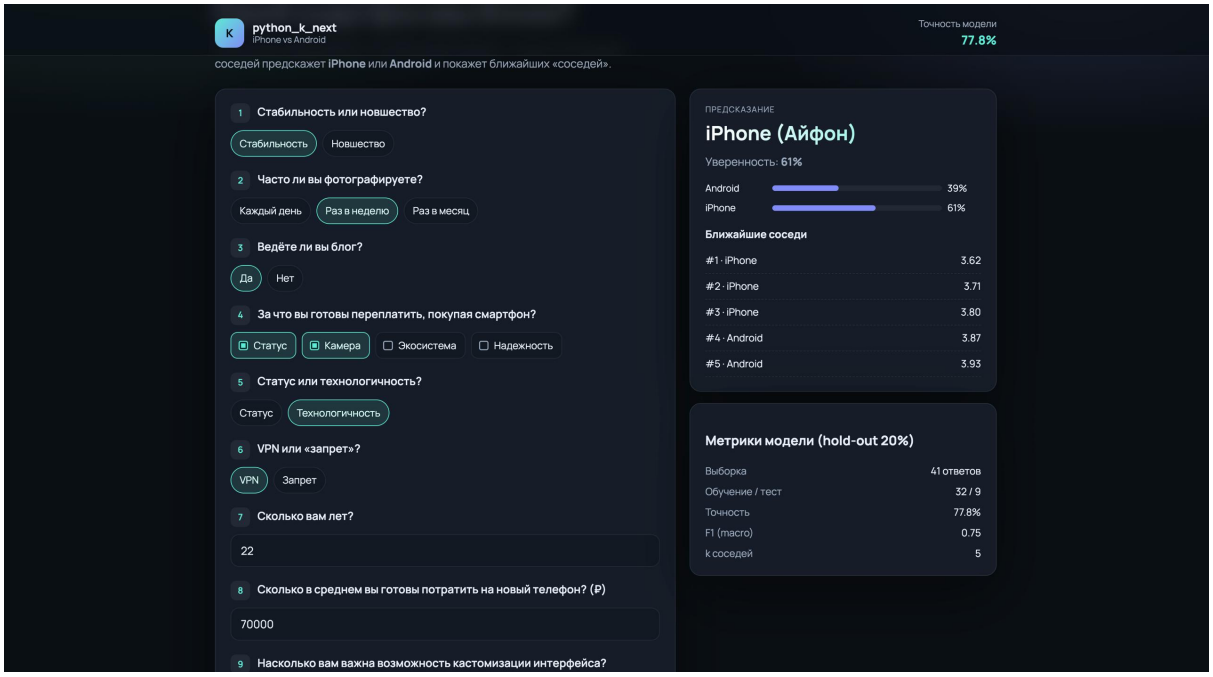


Рисунок 5 – Результат предсказания на основе опросника

Сравнение точности KNN для разного числа соседей (k)

Модель обучалась при k от 1 до 15 с двумя схемами взвешивания соседей («uniform» — равный голос, «distance» — голос обратно пропорционален расстоянию).

Accuracy (hold-out) — точность на тестовой выборке 20% (тот же сплит, что при основном обучении).

Accuracy (5-fold CV) — более устойчивая оценка по 5-блочной стратифицированной кросс-валидации на всех 41 наблюдениях.

Таблица 1 – Точность KNN в зависимости от числа соседей k

k (число соседей)	Тип весов	Accuracy (hold-out 80/20)	Accuracy (5-fold CV, среднее ± std)
1	uniform	0.889	0.731 ± 0.096
2	uniform	0.778	0.733 ± 0.086
3	uniform	0.778	0.708 ± 0.095
4	uniform	0.778	0.658 ± 0.049
5	uniform	0.778	0.706 ± 0.067
6	uniform	0.778	0.683 ± 0.057
7	uniform	0.778	0.681 ± 0.105
8	uniform	0.778	0.706 ± 0.103
9	uniform	0.778	0.681 ± 0.069
10	uniform	0.667	0.681 ± 0.069
11	uniform	0.778	0.731 ± 0.096
12	uniform	0.667	0.681 ± 0.069
13	uniform	0.889	0.733 ± 0.117
14	uniform	0.667	0.633 ± 0.081

15	uniform	0.889	0.683 ± 0.097
1	distance	0.889	0.731 ± 0.096
2	distance	0.889	0.731 ± 0.096
3	distance	0.778	0.708 ± 0.095
4	distance	0.778	0.756 ± 0.080
5	**distance**	**0.778**	**0.706 ± 0.067**
6	distance	0.778	0.731 ± 0.054
7	distance	0.778	0.681 ± 0.105
8	distance	0.778	0.731 ± 0.054
9	distance	0.778	0.681 ± 0.069
10	distance	0.778	0.756 ± 0.080
11	distance	0.778	0.731 ± 0.096
12	distance	0.778	0.731 ± 0.096
13	distance	0.889	0.733 ± 0.117
14	distance	0.778	0.756 ± 0.112
15	distance	0.889	0.683 ± 0.097

Вывод по практической работе

Целью практической работы был сбор собственного датасета и построение модели, предсказывающей операционную систему смартфона пользователя (iPhone или Android) по ответам на опросник. Для этого был самостоятельно собран датасет из 41 наблюдения путём анкетирования респондентов по 21 вопросу, охватывающему привычки использования смартфона, финансовые предпочтения, отношение к кастомизации и экосистемности. На основе этих данных построен пайплайн предобработки — кодирование категориальных признаков методом One-Hot Encoding, масштабирование числовых признаков (StandardScaler), разворачивание вопроса с множественным выбором в набор бинарных признаков — и обучена модель классификации методом k ближайших соседей (KNN).

Итоговая модель (k=5, вес «distance») показала accuracy 0,778 на отложенной тестовой выборке. Наиболее устойчивый результат кросс-валидации (≈0,756) достигается при k=4, k=10 или k=14 с весами по расстоянию, однако ввиду малого объёма выборки эта разница статистически не значима, а высокая точность hold-out-сплита при k=1 (0,889) объясняется переобучением на шум, а не реальным превосходством такого k — на кросс-валидации этот же k даёт заметно более скромный результат (0,731).

Таким образом, поставленная цель достигнута: собран собственный датасет и построена работоспособная модель, предсказывающая выбор iPhone или Android по ответам на

опросник, а результат оформлен в виде веб-приложения (FastAPI) с формой опроса и выдачей предсказания в реальном времени. Полученные метрики качества подтверждают, что ответы на вопросы анкеты действительно связаны с выбором операционной системы, хотя для более надёжного подбора гиперпараметра k и повышения точности модели требуется существенно больший объём данных — при 41 наблюдении и 9 тестовых примерах любые оценки accuracy имеют широкий доверительный интервал.